


Plan de Implementacion — Hackathon 36h

HackMTY26 · Altur Challenge: Defend the Bank Against Voice Deepfakes

Dos proyectos coordinados: el endpoint **POST /detect** (lo que se califica) y la capa de demo en vivo con Twilio + UI (diferenciador de originalidad).

Resumen ejecutivo

El reto solo califica automaticamente un endpoint HTTP (**POST /detect**) que recibe audio pregrabado y decide si la voz del llamante es sintetica. Twilio, la UI y la biometria/IoT son una **capa de demostracion** construida sobre el mismo motor de deteccion, no un sistema aparte. Por eso el plan prioriza siempre el Proyecto A y trata al Proyecto B como una extension oportunista.



Linea de tiempo — 36 horas

Pensada para trabajo en paralelo (2+ subequipos). El Proyecto A nunca se pausa; el Proyecto B se recorta primero si falta tiempo.

Horas	Proyecto A — /detect	Proyecto B — Twilio + UI	Hito de control
0–2h	Clonar repo, explorar dataset (balance de clases, duracion, calidad de audio).	Confirmar numero Twilio + ngrok/host estable. Repasar loopback ya probado.	Roles del equipo asignados.
2–6h	Endpoint /detect con heuristica simple (aunque sea debil) desplegado y respondiendo.	Disenar guion del agente: donde interrumpe, calla, pregunta info inexistente.	/detect responde 200 con JSON valido.
6–10h	Feature extraction acustico (MFCC, pitch, jitter/shimmer) + deteccion de piso de ruido / silencio digital (0 dBFS) + primer clasificador entrenado.	Integrar TTS del agente siguiendo el guion de trampas.	Primer modelo entrenado con metricas base (accuracy/AUC).
10–18h	Senal conversacional: VAD en canal agente, features de recuperacion en canal caller tras cada trampa.	Empaquetar audio de la llamada en vivo como WAV estereo y mandarlo al propio /detect.	Senal diferenciadora funcionando en al menos 1 caso de prueba.
18–24h	Fusion acustico + conversacional. Calibrar confidence (Brier score / isotonic regression).	UI v1 (React): forma de onda dual (wavesurfer.js) + desglose de score al subir un WAV.	Demo interna: subir un WAV y ver resultado explicado en pantalla.

Horas	Proyecto A — /detect	Proyecto B — Twilio + UI	Hito de control
24–30h	Validacion en holdout (acentos, compresion celular), export a ONNX Runtime, perfilado de latencia (objetivo <150 ms).	UI v2: vista de llamada en vivo con medidor de riesgo y marcadores en las trampas.	Latencia de inferencia medida, estable y documentada.
30–34h	Congelar modelo, desplegar en host de alta disponibilidad (no ngrok gratuito), redactar README tecnico.	Pulir flujo de demo en vivo end-to-end; recorte de alcance visual si hace falta tiempo.	Endpoint reachable de forma publica y permanente.
34–36h	Ensayo del pitch: robustez, originalidad, profundidad tecnica, feasibility, latencia.	Ensayo de la demo en vivo con jueces (guion de 15 min).	Equipo listo para preguntas de los jueces.

Proyecto A — Endpoint /detect (prioridad maxima)

A0

Exploracion de datos

Horas 0-2

- Clonar github.com/alturio/hackmtty26 y localizar el dataset de audios.
- Contar ejemplos humano vs. sintetico; revisar duracion, ruido y condiciones de llamada.
- Escuchar 10-15 muestras de cada clase para calibrar intuicion sobre el artefacto a detectar.

A1

Baseline desplegable

Horas 2-6

- FastAPI con POST /detect: decodifica WAV base64, separa canal 0 (caller) y canal 1 (agente).
- Heuristica simple como primer entregable (ej. energia en bandas altas) — el objetivo es tener algo evaluable desde el dia 1, no precision.
- Formato de respuesta exacto: {"is_synthetic": bool, "confidence": float}.

A2

Senal acustica reforzada

Horas 6-10

- Features: MFCC, estabilidad de pitch, jitter/shimmer, ausencia de micro-respiraciones, balance espectral.
- **Zero-Silence & Noise Floor**: detectar silencios digitales exactos (0.0 dBFS) producidos por drivers virtuales (VB-Cable) o TTS en streaming, en contraste con el ruido termico continuo de un microfono fisico real — una senal forense simple y muy dificil de falsificar.
- Clasificador ligero (LightGBM/XGBoost) entrenado sobre el dataset provisto.
- Alternativa rapida: modelo anti-spoofing preentrenado (tipo AASIST/RawNet2) solo recalibrado.

A3

Senal conversacional (diferenciador clave)

Horas 10-18

- VAD sobre canal 1 (agente) para localizar cada interrupcion, silencio o solape deliberado.
- En canal 0 (caller), medir latencia de recuperacion, continuidad espectral y "naturalidad del desorden" justo despues de cada trampa — una maquina se recupera de forma consistente, un humano no.
- Esta senal usa ambos canales, algo que un clasificador de audio generico no hace: es el diferencial de originalidad.

A4

Fusion y calibracion

Horas 18-24

- Combinar score acustico + score conversacional mediante un ensamble liviano calibrado.
- Calibrar confidence contra validacion (Brier score / isotonic regression) — se usa para desempatar y premia sistemas bien calibrados en la evaluacion automatica.

A5

Robustez, latencia y despliegue

Horas 24-30

- Validar en holdout: acentos, dispositivos y condiciones de llamada/compresion distintas a las de entrenamiento.
- Medir latencia de inferencia end-to-end (criterio explicito de evaluacion) y exportar a **ONNX Runtime** para garantizar **<150 ms** por prediccion.
- Desplegar en VPS/Cloud de alta disponibilidad durante toda la ventana de evaluacion y los 15 min de jueces (no depender de ngrok gratuito, cuya URL cambia al reiniciar).

A6

Documentacion

Horas 30-32

- README explicando el approach: por que se eligieron esas senales y como se combinan.
- Preparar respuestas para "does the team understand why it works" (criterio de technical depth).

Proyecto B — Twilio en vivo + capa de demo

No se califica en la ronda automatica. Su valor es mostrar en los 15 minutos de jueces que el mismo motor de deteccion funciona sobre una llamada telefonica real, no solo sobre el dataset. Se recorta primero si el tiempo aprieta.

B1

Conexion basica (ya completado)

Horas 0-2

- Webhook /incoming-call + WebSocket /media-stream con Twilio Media Streams.
- Prueba de eco verificada: audio del llamante se escucha de vuelta con latencia baja.

B2

Guion de trampas del agente

Horas 2-10

- Diseñar el guion de TTS: pedir que el usuario repita un dato, preguntar por informacion inexistente, interrumpir/callar a proposito — replicando exactamente las trampas descritas en el reto.
- Como el equipo controla el lado del agente, se puede provocar la senal conversacional a demanda.

B3

Puente hacia /detect

Horas 10-18

- Acumular audio de la llamada (caller + agente) en ventanas de ~5-10s.
- Empaquetar como WAV estereo en el mismo formato del reto y enviarlo al propio endpoint /detect.
- Reutiliza el motor del Proyecto A — nunca se entrena un segundo modelo distinto.

B4

Reaccion a riesgo alto (opcional)

Horas 18-24 (si sobra tiempo)

- Si /detect marca riesgo alto: pedir un segundo factor (ej. token fisico / RFID en Raspberry Pi) antes de continuar.
- Es la extension mas ambiciosa del plan original del equipo; solo se aborda si A y B3 ya estan solidos.

Rol de la UI (Frontend React)

La UI no es decorativa: ataca directamente los criterios de **originalidad** y **technical depth** al convertir una caja negra en un sistema explicable visualmente.

Visualizador estereo en paralelo (wavesurfer.js). Renderizado sincronizado del Canal 1 (Agente) arriba y Canal 0 (Caller) abajo, para ver la reaccion del llamante alineada en el tiempo con el estimulo del agente.

Marcado interactivo de eventos. Marcadores visuales en el timeline donde el agente disparo la trampa (interrupcion/silencio) y resaltado de la latencia de respuesta del usuario justo despues.

Desglose de metricas forenses. Medidor que separa cuanto apporto el analisis fisico (piso de ruido, silencio digital) frente a la senal conversacional — convierte el veredicto en algo explicable, no una caja negra.

Historial transaccional. Registro de llamadas auditadas con semaforo tipo bancario (Aprobada / Congelada), para mostrar consistencia sobre varios casos sin depender de una sola prueba en vivo frente a los jueces.

Criterios de evaluacion — que fase los cubre

Criterio	Cubierto principalmente por
Robustness	A2 (piso de ruido/silencio digital) + A5 (validacion holdout frente a compresion celular)

Criterio	Cubierto principalmente por
Originality	A3 (senal conversacional entre canales) + B2/B3 (trampas deliberadas en vivo)
Technical depth	A4 (fusion y calibracion) + UI explicable (wavesurfer.js + desglose forense) + README con rigor DSP (A6)
Feasibility	A5 (despliegue en host de alta disponibilidad) + B3 (prueba en llamada telefonica real)
Latency	A5 (clasificadores ligeros exportados a ONNX, perfilado end-to-end <150 ms)

Regla de contingencia

Si el tiempo aprieta: el Proyecto A (/detect) nunca se sacrifica — es lo unico que califica en la ronda automatica. Se recorta primero el pulido estetico de la UI, manteniendo unicamente el dashboard funcional y el loopback de Twilio (B1) como demo de respaldo.

Reparto de responsabilidades del equipo

Equipo de 4: Alessandro y Gera cubren el Proyecto A en paralelo (la senal conversacional no depende del endpoint para prototiparse); Alejandro y Dan cubren el Proyecto B por capas (motor de la llamada vs. interfaz).

Persona	Fases	Que construye
Alessandro	A0 (junto) → A1 → A2 → lidera A5	Endpoint FastAPI (/detect, decode WAV base64, split canales) + senal acustica (MFCC, pitch, jitter/shimmer, piso de ruido) + despliegue/hosting y ONNX/latencia.
Gera	A0 (junto) → A3 → apoya A5	Senal conversacional: VAD sobre canal 1 para ubicar interrupciones/silencios, features de recuperacion en canal 0. Arranca en paralelo desde temprano, directo sobre el dataset.
Ambos (Alessandro+Gera)	A4 (hora 18-24) + A6	Fusion de los dos scores + calibracion de confidence, y el README tecnico.
Alejandro	B2 → B3	Guion de trampas del agente (repetir info, pregunta inexistente, interrumpir/callar) + TTS, y el puente que empaqueta audio de la llamada en vivo hacia /detect.
Dan	UI v1 → UI v2 → historial	Visualizador estereo (wavesurfer.js), marcadores de eventos, desglose forense y el historial transaccional con semaforo bancario.
Ambos (Alejandro+Dan)	B4 (opcional)	Solo si sobra tiempo: reaccion a riesgo alto (RFID/Raspberry Pi).

Puntos de sincronizacion obligatorios

Hora 2: Alessandro comparte el contrato real de /detect (aunque devuelva un valor dummy) para que Dan y Alejandro construyan contra algo real desde ya.

Hora 10: check rapido de los 4 — senal acustica y conversacional con resultados preliminares, guion de trampas integrado en la llamada.

Hora 18: Alessandro+Gera fusionan sus senales; Alejandro conecta B3 contra el /detect ya real, no el dummy.

Hora 24: demo interna cruzada — Dan prueba su UI contra el modelo real; revision de que falta para jueces.