


Plan de Implementacion — Hackathon 36h

HackMTY26 · Altur Challenge: Defend the Bank Against Voice Deepfakes

Dos proyectos coordinados: el endpoint **POST /detect** (lo que se califica) y la capa de demo en vivo con Twilio + UI (diferenciador de originalidad).

Resumen ejecutivo

El reto solo califica automaticamente un endpoint HTTP (**POST /detect**) que recibe audio pregrabado y decide si la voz del llamante es sintetica. Twilio, la UI y la biometria/IoT son una **capa de demostracion** construida sobre el mismo motor de deteccion, no un sistema aparte. Por eso el plan prioriza siempre el Proyecto A y trata al Proyecto B como una extension oportunista.



Linea de tiempo — 36 horas

Pensada para trabajo en paralelo (2+ subequipos). El Proyecto A nunca se pausa; el Proyecto B se recorta primero si falta tiempo.

Horas	Proyecto A — /detect	Proyecto B — Twilio + UI	Hito de control
0–2h	Clonar repo, explorar dataset (balance de clases, duracion, calidad de audio).	Confirmar numero Twilio + ngrok/host estable. Repasar loopback ya probado.	Roles del equipo asignados.
2–6h	Endpoint /detect con heuristica simple (aunque sea debil) desplegado y respondiendo.	Disenar guion del agente: donde interrumpe, calla, pregunta info inexistente.	/detect responde 200 con JSON valido.
6–10h	Feature extraction acustico (MFCC, pitch, jitter/shimmer) + primer clasificador entrenado.	Integrar TTS del agente siguiendo el guion de trampas.	Primer modelo entrenado con metricas base (accuracy/AUC).
10–18h	Senal conversacional: VAD en canal agente, features de recuperacion en canal caller tras cada trampa.	Empaquetar audio de la llamada en vivo como WAV estereo y mandarlo al propio /detect.	Senal diferenciadora funcionando en al menos 1 caso de prueba.
18–24h	Fusion acustico + conversacional. Calibrar confidence (Brier score / revision manual).	UI v1: panel para arrastrar un WAV y ver veredicto + desglose de senales.	Demo interna: subir un WAV y ver resultado explicado en pantalla.
24–30h	Validacion en set de holdout, pruebas de robustez (acentos, condiciones de llamada), perfilar latencia.	UI v2: vista de llamada en vivo con medidor de riesgo en tiempo real.	Latencia de inferencia medida y aceptable.

Horas	Proyecto A — /detect	Proyecto B — Twilio + UI	Hito de control
30–34h	Congelar modelo, desplegar version final en host estable (no ngrok gratuito), redactar README.	Pulir flujo de demo en vivo end-to-end; recorte de alcance si hace falta tiempo.	Endpoint reachable de forma persistente.
34–36h	Ensayo del pitch: robustez, originalidad, profundidad tecnica, feasibility, latencia.	Ensayo de la demo en vivo con jueces (guion de 15 min).	Equipo listo para preguntas de los jueces.

Proyecto A — Endpoint /detect (prioridad maxima)

A0

Exploracion de datos

Horas 0-2

- Clonar github.com/alturio/hackmtty26 y localizar el dataset de audios.
- Contar ejemplos humano vs. sintetico; revisar duracion, ruido y condiciones de llamada.
- Escuchar 10-15 muestras de cada clase para calibrar intuicion sobre el artefacto a detectar.

A1

Baseline desplegable

Horas 2-6

- FastAPI con POST /detect: decodifica WAV base64, separa canal 0 (caller) y canal 1 (agente).
- Heuristica simple como primer entregable (ej. energia en bandas altas) — el objetivo es tener algo evaluable desde el dia 1, no precision.
- Formato de respuesta exacto: {"is_synthetic": bool, "confidence": float}.

A2

Senal acustica

Horas 6-10

- Features: MFCC, estabilidad de pitch, jitter/shimmer, ausencia de micro-respiraciones, artefactos espectrales.
- Clasificador ligero (gradient boosting o red pequena) entrenado sobre el dataset provisto.
- Alternativa rapida: modelo anti-spoofing preentrenado (tipo AASIST/RawNet2) solo recalibrado.

A3

Senal conversacional (diferenciador clave)

Horas 10-18

- VAD sobre canal 1 (agente) para localizar cada interrupcion, silencio o solape deliberado.
- En canal 0 (caller), medir latencia de recuperacion, continuidad espectral y "naturalidad del desorden" justo despues de cada trampa — una maquina se recupera de forma consistente, un humano no.
- Esta senal usa ambos canales, algo que un clasificador de audio generico no hace: es el diferencial de originalidad.

A4

Fusion y calibracion

Horas 18-24

- Combinar score acustico + score conversacional (ensemble simple o meta-clasificador liviano).
- Calibrar confidence contra un set de validacion — se usa para desempatar y premia sistemas bien calibrados.

A5

Robustez, latencia y despliegue

Horas 24-30

- Validar en holdout: acentos, dispositivos y condiciones de llamada distintas a las de entrenamiento.
- Medir latencia de inferencia end-to-end (criterio explicito de evaluacion).
- Desplegar en host estable y persistente durante toda la ventana de evaluacion y los 15 min de jueces (no depender de ngrok gratuito, cuya URL cambia al reiniciar).

A6

Documentacion

Horas 30-32

- README explicando el approach: por que se eligieron esas senales y como se combinan.
- Preparar respuestas para "does the team understand why it works" (criterio de technical depth).

Proyecto B — Twilio en vivo + capa de demo

No se califica en la ronda automatica. Su valor es mostrar en los 15 minutos de jueces que el mismo motor de deteccion funciona sobre una llamada telefonica real, no solo sobre el dataset. Se recorta primero si el tiempo aprieta.

B1

Conexion basica (ya completado)

Horas 0-2

- Webhook /incoming-call + WebSocket /media-stream con Twilio Media Streams.
- Prueba de eco verificada: audio del llamante se escucha de vuelta con latencia baja.

B2

Guion de trampas del agente

Horas 2-10

- Diseñar el guion de TTS: pedir que el usuario repita un dato, preguntar por informacion inexistente, interrumpir/callar a proposito — replicando exactamente las trampas descritas en el reto.
- Como el equipo controla el lado del agente, se puede provocar la senal conversacional a demanda.

B3

Puente hacia /detect

Horas 10-18

- Acumular audio de la llamada (caller + agente) en ventanas de ~5-10s.
- Empaquetar como WAV estereo en el mismo formato del reto y enviarlo al propio endpoint /detect.
- Reutiliza el motor del Proyecto A — nunca se entrena un segundo modelo distinto.

B4

Reaccion a riesgo alto (opcional)

Horas 18-24 (si sobra tiempo)

- Si /detect marca riesgo alto: pedir un segundo factor (ej. token fisico / RFID en Raspberry Pi) antes de continuar.
- Es la extension mas ambiciosa del plan original del equipo; solo se aborda si A y B3 ya estan solidos.

Rol de la UI

La UI no es decorativa: ataca directamente los criterios de **originalidad** y **technical depth**, porque demostrar visualmente por que funciona el sistema es mas convincente que explicarlo con logs.

Panel de prueba del dataset. Arrastrar un WAV, llamar a /detect, mostrar veredicto + confianza + desglose de cuanto aporoto la senal acustica vs. la conversacional. Convierte el modelo de caja negra en algo explicable.

Vista de llamada en vivo (Twilio). Forma de onda o transcripcion en tiempo real con un medidor de riesgo que sube justo despues de cada trampa (interrupcion/silencio) — ensena la senal funcionando en vez de describirla.

Historial comparativo. Tabla de llamadas ya procesadas con su veredicto, para mostrar robustez sobre varios casos sin tener que correr cada uno en vivo frente a los jueces.

Criterios de evaluacion — que fase los cubre

Criterio	Cubierto principalmente por
Robustness	A5 (validacion en holdout con acentos/condiciones distintas)
Originality	A3 (senal conversacional entre canales) + B2/B3 (trampas provocadas en vivo)
Technical depth	A4 (fusion/calibracion) + UI (panel explicable) + README (A6)

Criterio	Cubierto principalmente por
Feasibility	A5 (despliegue estable) + B3 (funciona sobre audio real de llamada, no solo dataset)
Latency	A5 (perfilado de latencia de inferencia)

Regla de contingencia

Si el tiempo aprieta: el Proyecto A (/detect) nunca se sacrifica — es lo unico que califica en la ronda automatica. Se recorta primero B4, luego B3/B2, manteniendo siempre al menos el loopback de Twilio (B1) como demo de respaldo.